

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN



ĐỒ ÁN CUỐI KỲ
XỬ LÝ NGÔN NGỮ TỰ NHIÊN NÂNG CAO
CHINESE OCR
(Đề tài 16)

Giảng viên hướng dẫn: PGS. TS. Đinh Điền

TS. Nguyễn Hồng Bửu Long

TS. Lương An Vinh

Học viên thực hiện: 24C11021 - Lê Minh Phục

24C11035 - Nguyễn Thế Vinh

25C15034 - Trần Ngọc Bảo

25C15062 - Nguyễn Đăng Thới Toàn

Thành phố Hồ Chí Minh – 2026

1 Giới thiệu

1.1 Mục tiêu của đề án

Đề án nghiên cứu bài toán nhận dạng văn bản Hán cổ trên bộ dữ liệu **MTHv2** với **PaddleOCR**. Chuỗi thực nghiệm chính sử dụng **PP-OCRv5**, với các bước cải tiến gồm fine-tuning trên dữ liệu mục tiêu, mở rộng vocabulary và tăng cường các mẫu chứa ký tự hiếm. Ngoài ra, nhóm thực hiện thêm một thí nghiệm với **PP-OCRv6 Medium** để so sánh hiệu năng trên cùng bộ dữ liệu.

Mục tiêu của đề án gồm:

- Xây dựng baseline và fine-tune PP-OCRv5 trên MTHv2.
- Cải thiện khả năng nhận dạng thông qua mở rộng vocabulary và xử lý ký tự hiếm.
- Đánh giá các cấu hình bằng CER, Exact Match Accuracy và phân tích lỗi.
- So sánh bổ sung với PP-OCRv6 Medium.

1.2 Bài toán được giao

Đầu vào của hệ thống là ảnh một dòng văn bản Hán cổ, đầu ra là chuỗi ký tự dự đoán tương ứng.

Ảnh dòng văn bản $\rightarrow$ OCR Recognition $\rightarrow$ Chuỗi ký tự dự đoán $\rightarrow$ Đánh giá

Trong đề án, **PP-OCRv5_server_rec** được sử dụng cho chuỗi thực nghiệm B0–B3, trong khi **PP-OCRv6_medium_rec** được khảo sát như một cấu hình so sánh độc lập.

1.3 Phạm vi và kết quả mong đợi

Các cấu hình thực nghiệm gồm:

- **B0**: PP-OCRv5 pretrained.
- **B1**: fine-tuning trên MTHv2.
- **B2**: mở rộng vocabulary.
- **B3**: tăng cường mẫu chứa ký tự hiếm.
- **PP-OCRv6 Medium**: thí nghiệm so sánh bổ sung.

Kết quả mong đợi là xây dựng được một quy trình OCR có thể tái lập, cải thiện độ chính xác nhận dạng so với baseline và xác định các nhóm lỗi chính còn tồn tại.

2 Dữ liệu, mã nguồn và công cụ sử dụng

2.1 Mô tả dữ liệu đầu vào

Đồ án sử dụng bộ dữ liệu **MTHv2**, gồm ảnh tài liệu Hán cổ cùng các annotation về vị trí và nội dung văn bản.

Trước khi huấn luyện, ảnh gốc được tiền xử lý dựa trên tọa độ polygon của từng vùng văn bản. Các vùng này được hiệu chỉnh phối cảnh, cắt khối ảnh gốc và chuẩn hóa hướng ảnh để phù hợp với đầu vào của mô hình nhận dạng PaddleOCR.

Dữ liệu được phân chia theo phân hoạch chính thức của MTHv2 với tỷ lệ train:test là 3:1. Cụ thể, tập train chính thức gồm **2.399 trang** và tập test gồm **800 trang**. Từ tập train, nhóm tiếp tục tách **10% số trang** làm validation, thu được **2.159 trang train** và **240 trang validation**. Việc phân chia được thực hiện ở mức trang trước khi cắt ảnh nhằm tránh rò rỉ dữ liệu giữa các tập.

2.2 Nguồn dữ liệu và mã nguồn

Bộ dữ liệu MTHv2 được cung cấp bởi HCIILAB tại: [MTHv2_Datasets_Release](#).

Bản dữ liệu gốc có thể tải tại: [Google Drive – MTHv2 Raw Dataset](#).

Để thuận tiện cho việc tái lập kết quả, nhóm cũng cung cấp bản dữ liệu đã được tiền xử lý tại: [Kaggle – MTHv2 Processed Dataset](#).

Toàn bộ mã nguồn, notebook huấn luyện và hướng dẫn tái lập được công bố tại: [GitHub – NLP_Submission](#).

Mô hình chính được sử dụng là **PP-OCRv5_server_rec** thuộc framework **PaddleOCR**. Mô hình pretrained được sử dụng làm baseline, sau đó được fine-tune và cải tiến trên dữ liệu MTHv2. Ngoài ra, **PP-OCRv6_medium_rec** được sử dụng trong một thí nghiệm so sánh bổ sung trên cùng bộ dữ liệu.

Các checkpoint đã huấn luyện được cung cấp tại: [Google Drive – Trained Models](#).

3 Quy trình thực hiện

3.1 Mô tả tổng quan quy trình

Quy trình thực hiện gồm chuẩn bị dữ liệu, tiền xử lý ảnh, xây dựng baseline, fine-tune mô hình, mở rộng vocabulary, tăng cường mẫu chứa ký tự hiếm và đánh giá kết quả.

Sau tiền xử lý, PP-OCRv5 pretrained được sử dụng để xây dựng baseline B0 và làm điểm khởi tạo cho B1 và B2. B3 tiếp tục fine-tune từ checkpoint tốt nhất của B2.




Figure 1: Sơ đồ chuỗi cải tiến chính trên PP-OCRv5

Trong chuỗi cải tiến chính B0–B3, mô hình **PP-OCRv5_server_rec** được sử dụng xuyên suốt để bảo đảm tính nhất quán khi so sánh. PP-OCRv6 Medium được khảo sát riêng như một thí nghiệm so sánh bổ sung.

3.2 Các bước thực hiện chính

3.2.1 Chuẩn bị và tiền xử lý dữ liệu

Nhóm sử dụng phân hoạch train/test chính thức của MTHv2 và tách 10% số trang từ tập train làm validation. Từ annotation polygon, các vùng text-line được cắt và chuẩn hóa hướng để tạo dữ liệu đầu vào cho mô hình recognition.

Sau tiền xử lý, mỗi mẫu gồm một ảnh dòng văn bản và ground truth tương ứng, được lưu trong manifest phục vụ huấn luyện và đánh giá.

3.2.2 B0 – Mô hình baseline

B0 sử dụng trực tiếp mô hình pretrained **PP-OCRv5_server_rec** mà không fine-tune trên MTHv2. Kết quả của B0 được sử dụng làm mốc so sánh cho các cấu hình tiếp theo.

3.2.3 B1 – Fine-tune trên MTHv2

B1 được xây dựng nhằm đánh giá mức độ cải thiện khi mô hình pretrained được thích nghi trực tiếp với miền dữ liệu Hán cổ. Mô hình **PP-OCRv5_server_rec** được khởi tạo từ trọng số pretrained chính thức và tiếp tục huấn luyện trên tập train MTHv2, trong khi tập validation được sử dụng để theo dõi quá trình huấn luyện và lựa chọn checkpoint tốt nhất.

Ở giai đoạn này, nhóm giữ nguyên vocabulary mặc định của PP-OCRv5 và chưa áp dụng các thay đổi về phân phối dữ liệu. Do đó, B1 có thể được xem như một phép đo trực tiếp ảnh hưởng của domain adaptation: sự khác biệt giữa mô hình pretrained tổng quát và mô hình đã được fine-tune trên tài liệu Hán cổ.

Kết quả và phân tích lỗi của B1 sau đó được sử dụng làm cơ sở cho các thí nghiệm tiếp theo. Đặc biệt, nhóm nhận thấy một lượng đáng kể lỗi deletion xuất hiện tại những ký tự có trong ground truth của MTHv2 nhưng không tồn tại trong vocabulary mặc định của PP-OCRv5. Quan sát này dẫn đến thí nghiệm B2.

3.2.4 B2 – Mở rộng vocabulary

B2 tập trung xử lý một giới hạn mang tính cấu trúc của mô hình recognition: mô hình không thể sinh ra một ký tự nếu ký tự đó không tồn tại trong vocabulary đầu ra, bất kể đặc trưng hình ảnh của ký tự có được encoder biểu diễn tốt đến đâu.

Phân tích B1 cho thấy MTHv2 chứa nhiều ký tự Hán cổ, dị thể và ký tự hiếm chưa được bao phủ bởi vocabulary mặc định của PP-OCRv5. Các trường hợp này thường biểu hiện dưới dạng deletion hoặc bị thay thế bằng một ký tự khác có hình dạng gần giống.

Để xử lý vấn đề này, nhóm xây dựng vocabulary mở rộng dựa **chỉ trên tập train**, không sử dụng thông tin từ validation hoặc test. Gọi V_{base} là vocabulary mặc định của PP-OCRv5 và C_{train} là tập ký tự xuất hiện trong ground truth của tập train, vocabulary mới được xây dựng theo:

$$V_{\text{B2}} = V_{\text{base}} \cup (C_{\text{train}} \setminus V_{\text{base}}).$$

Các ký tự đã tồn tại trong vocabulary gốc được giữ nguyên thứ tự và chỉ các ký tự còn thiếu mới được bổ sung vào cuối dictionary. Cách xây dựng này bảo toàn toàn bộ index của vocabulary ban đầu, đồng thời mở rộng không gian đầu ra để mô hình có khả năng sinh thêm các ký tự Hán cổ xuất hiện trong dữ liệu MTHv2.

Để quá trình tạo vocabulary có thể tái lập, các ký tự mới được sắp xếp theo tần suất xuất hiện giảm dần trong tập train; nếu có cùng tần suất, Unicode code point được sử dụng làm tiêu chí

phụ. Script tạo vocabulary cũng kiểm tra lại rằng toàn bộ phần đầu của dictionary mới hoàn toàn trùng với dictionary gốc.

Sau khi xây dựng vocabulary mở rộng, B2 được khởi tạo lại từ trọng số pretrained PP-OCRv5 và fine-tune trên cùng tập train như B1. Việc khởi tạo B1 và B2 độc lập từ cùng pretrained checkpoint giúp giảm ảnh hưởng của continued fine-tuning và làm rõ hơn tác động của việc thay đổi vocabulary.

Điểm chính của B2 không phải thay đổi kiến trúc PP-OCRv5 mà là điều chỉnh không gian ký tự đầu ra dựa trên đặc trưng thực tế của miền dữ liệu. Kết quả thực nghiệm cho thấy đây là một cải tiến quan trọng, đặc biệt đối với các lỗi deletion liên quan đến ký tự ngoài vocabulary.

3.2.5 B3 – Tăng cường mẫu chứa ký tự hiếm

Sau khi mở rộng vocabulary ở B2, số lỗi liên quan đến ký tự ngoài từ điển giảm đáng kể. Tuy nhiên, phân tích tiếp cho thấy việc một ký tự đã tồn tại trong vocabulary không đồng nghĩa rằng mô hình có thể nhận dạng tốt ký tự đó. Một số ký tự xuất hiện rất ít trong tập train nên mô hình vẫn có xu hướng dự đoán sang các ký tự phổ biến hơn.

Từ quan sát này, nhóm định nghĩa các ký tự xuất hiện không quá **50 lần** trong tập train là ký tự hiếm. Trong tổng số 72.563 dòng huấn luyện, có 23.765 dòng chứa ít nhất một ký tự thuộc nhóm này.

Thay vì tạo dữ liệu tổng hợp ở mức ký tự riêng lẻ, nhóm tăng tần suất xuất hiện của các mẫu thực tế bằng cách oversample các dòng chứa ít nhất một ký tự hiếm với hệ số 3. Sau bước này, kích thước tập train tăng từ 72.563 lên 120.093 dòng. Cách tiếp cận này giúp tăng số lần mô hình quan sát các ký tự hiếm trong chính ngữ cảnh hình ảnh và chuỗi văn bản gốc của chúng.

Khác với B2, B3 không được khởi tạo lại từ pretrained checkpoint mà tiếp tục fine-tune từ checkpoint tốt nhất của B2. Vocabulary mở rộng được giữ nguyên, trong khi learning rate được giảm xuống nhằm thực hiện quá trình fine-tuning bổ sung trên phân phối dữ liệu mới.

B3 vì vậy tập trung vào một vấn đề khác với B2: B2 giải quyết *khả năng biểu diễn ký tự trong không gian đầu ra*, còn B3 hướng đến *sự mất cân bằng về tần suất xuất hiện của các ký tự trong dữ liệu huấn luyện*. Hai bước này tạo thành hai giai đoạn cải tiến liên tiếp dựa trên phân tích lỗi của mô hình.

3.3 Thiết lập thực nghiệm

B1 và B2 được khởi tạo độc lập từ PP-OCRv5 pretrained. B3 tiếp tục fine-tune từ checkpoint tốt nhất của B2 với learning rate thấp hơn.

Các tham số huấn luyện chính được trình bày trong Bảng 1.

Bảng 1: Các thiết lập huấn luyện chính của chuỗi thí nghiệm PP-OCRv5

Tham số	B1	B2	B3
Khởi tạo	PP-OCRv5 pretrained	PP-OCRv5 pretrained	B2 best checkpoint
Vocabulary	Mặc định	Mở rộng	Mở rộng
Training data	Train gốc	Train gốc	Rare oversampled
Số epoch	20	20	10
Learning rate	5×10^{-4}	5×10^{-4}	5×10^{-5}
LR scheduler	Cosine	Cosine	Cosine
Validation interval	500 iterations	500 iterations	100 iterations
Checkpoint selection	Val. accuracy	Val. accuracy	Val. accuracy

B1 và B2 sử dụng cùng cấu hình chính để đánh giá ảnh hưởng của việc mở rộng vocabulary. B3 tiếp tục fine-tune từ B2 với learning rate thấp hơn và thay đổi phân phối dữ liệu bằng rare-character oversampling.

3.4 Thí nghiệm so sánh bổ sung với PP-OCRv6 Medium

Ngoài chuỗi B0–B3, nhóm fine-tune **PP-OCRv6_medium_rec** trên cùng dữ liệu MTHv2 và đánh giá trên cùng tập test. Thí nghiệm này được sử dụng như một cấu hình so sánh độc lập và không thuộc chuỗi cải tiến dựa trên phân tích lỗi B1–B3.

3.5 Cách đánh giá kết quả

Các cấu hình được đánh giá trên cùng tập test MTHv2 bằng hai chỉ số chính là **Character Error Rate (CER)** và **Exact Match Accuracy**.

$$CER = \frac{S + D + I}{N},$$

trong đó S , D , I lần lượt là số lỗi substitution, deletion và insertion, còn N là tổng số ký tự ground truth. CER càng thấp thì kết quả nhận dạng càng tốt.

Exact Match Accuracy là tỷ lệ số dòng mà chuỗi dự đoán khớp hoàn toàn với ground truth.

Ngoài các chỉ số tổng thể, nhóm phân tích lỗi ở mức ký tự dựa trên khoảng cách Levenshtein, độ bao phủ vocabulary, các ký tự ngoài từ điển (OOV) và tần suất ký tự trong tập train.

4 Kết quả đạt được

4.1 Kết quả thực nghiệm

Các mô hình được đánh giá trên cùng tập test MTHv2 gồm **25.262 mẫu**, tương ứng **263.342 ký tự ground truth**. Kết quả được trình bày trong Bảng 2.

Bảng 2: Kết quả các cấu hình trên tập test MTHv2

Cấu hình	CER	Exact Match	Confidence
B0 – Pretrained	11,54%	38,91%	0,8652
B1 – Fine-tuning	3,25%	75,98%	0,9821
B2 – Mở rộng vocabulary	2,39%	82,46%	0,9766
B3 – Tăng cường mẫu ký tự hiếm	2,19%	83,85%	0,9735
PP-OCRv6 Medium – Fine-tuning	3,51%	74,22%	0,9773

Xét chuỗi cải tiến chính B0–B3, fine-tuning trên MTHv2 giúp CER giảm mạnh từ 11,54% ở B0 xuống 3,25% ở B1. Mở rộng vocabulary ở B2 tiếp tục giảm CER xuống 2,39%, trong khi B3 đạt kết quả tốt nhất với CER **2,19%** và Exact Match Accuracy **83,85%**.

Trong thí nghiệm bổ sung, PP-OCRv6 Medium đạt CER 3,51% và Exact Match Accuracy 74,22%. Kết quả này chưa vượt B1 sử dụng PP-OCRv5, cho thấy trong thiết lập hiện tại, một recognizer thế hệ mới hơn không tự động mang lại kết quả tốt hơn trên MTHv2.

4.2 Phân tích kết quả

Cải thiện lớn nhất đạt được từ B0 sang B1, cho thấy mô hình pretrained chưa thích nghi tốt với đặc trưng của tài liệu Hán cổ và fine-tuning trên dữ liệu cùng miền đóng vai trò quan trọng.

Phân tích B1 cho thấy nhiều lỗi deletion liên quan đến các ký tự không có trong vocabulary mặc định. Đây là cơ sở để xây dựng B2 bằng cách mở rộng tập ký tự nhận dạng. Sau cải tiến, lỗi deletion giảm mạnh và CER tiếp tục được cải thiện.

Sau B2, lỗi OOV không còn là nguyên nhân chính. Phân tích tần suất cho thấy mô hình vẫn gặp khó khăn với các ký tự hiếm, từ đó dẫn đến B3 với chiến lược oversampling các dòng chứa ký tự có tần suất thấp. B3 tiếp tục cải thiện CER, tuy nhiên do mô hình đồng thời được continued fine-tuning từ B2, cần thêm thí nghiệm đối chứng để tách biệt hoàn toàn đóng góp của oversampling.

Các lỗi còn lại chủ yếu tập trung ở substitution, đặc biệt giữa các ký tự có hình dạng tương tự, các dị thể chữ Hán và trường hợp mô hình ưu tiên ký tự phổ biến thay cho ký tự hiếm.

5 Phân tích lỗi và thảo luận

5.1 Phân tích lỗi

Bên cạnh các chỉ số tổng thể, nhóm phân tích kết quả ở mức ký tự dựa trên khoảng cách Levenshtein, độ bao phủ vocabulary, các ký tự ngoài từ điển (OOV) và tần suất ký tự trong tập train. Phân tích này được sử dụng để xác định nguyên nhân sai số của từng cấu hình và làm cơ sở cho các bước cải tiến tiếp theo.

5.2 Phân tích mô hình B1

B1 đạt CER 3,25% và Exact Match Accuracy 75,98%, với 8.563 lỗi ký tự gồm 4.506 substitution, 3.889 deletion và 168 insertion.

Tập test chứa 438 ký tự không có trong vocabulary mặc định của PP-OCrv5, xuất hiện tổng cộng 3.684 lần, tương ứng khoảng 1,40% số ký tự ground truth. Trong nhóm deletion được phân tích, phần lớn lỗi liên quan đến các ký tự OOV. Kết quả này cho thấy giới hạn của vocabulary mặc định là một nguyên nhân quan trọng gây lỗi deletion ở B1.

5.3 Hiệu quả của việc mở rộng vocabulary

B2 đạt CER 2,39% và Exact Match Accuracy 82,46%. Số deletion giảm mạnh từ 3.889 ở B1 xuống còn 231 ở B2.

Số ký tự OOV trong tập test giảm từ 438 xuống 144, trong khi số lần xuất hiện của các ký tự OOV giảm từ 3.684 xuống 213, tương ứng khoảng 0,08% số ký tự ground truth. Điều này cho thấy việc mở rộng vocabulary đã giải quyết hiệu quả phần lớn lỗi do mô hình không thể sinh các ký tự ngoài từ điển.

Sau khi deletion giảm mạnh, substitution trở thành dạng lỗi chiếm ưu thế. Nhiều trường hợp liên quan đến các ký tự có hình dạng gần nhau hoặc các dị thể chữ Hán, chẳng hạn 為 → 爲, 明 → 明, 真 → 眞 và 隨 → 隨.

5.4 Tăng cường mẫu ký tự hiếm ở B3

Các ký tự xuất hiện không quá 50 lần trong tập train được xem là ký tự hiếm. Trong 72.563 dòng huấn luyện, có 23.765 dòng chứa ít nhất một ký tự hiếm. Các dòng này được oversample với hệ số 3, làm tập train tăng lên 120.093 dòng.

B3 tiếp tục fine-tune từ checkpoint tốt nhất của B2 trên tập dữ liệu tăng cường, đạt CER 2,19% và Exact Match Accuracy 83,85%. Phân tích substitution cho thấy khoảng 62,31% trường hợp mô hình dự đoán sang ký tự có tần suất cao hơn ground truth, cho thấy mất cân bằng tần suất ký tự vẫn ảnh hưởng đến kết quả.

5.5 Thảo luận

Chuỗi cải tiến B1–B3 được xây dựng dựa trên phân tích lỗi của từng giai đoạn. B1 cho thấy OOV là nguyên nhân quan trọng gây deletion, từ đó dẫn đến mở rộng vocabulary ở B2. Sau khi vấn đề OOV giảm đáng kể, mất cân bằng tần suất ký tự trở thành một hạn chế nổi bật và là cơ sở cho chiến lược oversampling ở B3.

Từ B1 đến B3, CER giảm từ 3,25% xuống 2,19%. Tuy nhiên, các lỗi còn lại chủ yếu là substitution giữa các ký tự có hình dạng tương tự, dị thể chữ Hán và các trường hợp mô hình ưu tiên ký tự phổ biến hơn ký tự hiếm.

Do B3 vừa áp dụng oversampling vừa tiếp tục fine-tune từ B2, cần thêm thí nghiệm đối chứng để tách biệt hoàn toàn đóng góp của hai yếu tố này.

6 Kết luận và hướng phát triển

6.1 Những nội dung đã hoàn thành

Đồ án đã xây dựng và cải tiến quy trình nhận dạng văn bản Hán cổ trên bộ dữ liệu MTHv2, với chuỗi thực nghiệm chính dựa trên PP-OCRv5 và một thí nghiệm so sánh bổ sung sử dụng PP-OCRv6 Medium.

Các nội dung chính đã thực hiện gồm:

- Tiền xử lý dữ liệu MTHv2 và xây dựng baseline từ mô hình pretrained PP-OCRv5_server_rec.
- Fine-tune mô hình, mở rộng vocabulary và tăng cường các mẫu chứa ký tự hiếm dựa trên phân tích lỗi.
- Cải thiện CER từ 11,54% ở baseline xuống **2,19%** ở B3, với Exact Match Accuracy đạt **83,85%**.
- Phân tích các lỗi substitution, deletion và insertion để xác định các nguyên nhân sai sót còn lại.
- Thực hiện thêm thí nghiệm với PP-OCRv6 Medium để so sánh hiệu năng trên cùng bộ dữ liệu.

6.2 Những hạn chế còn tồn tại

- Mô hình vẫn gặp khó khăn với các ký tự hiếm, dị thể chữ Hán và các ký tự có hình dạng tương tự.
- Các lỗi còn lại chủ yếu tập trung ở substitution và xu hướng dự đoán ký tự phổ biến thay cho ký tự hiếm.
- Chưa thực hiện đầy đủ các thí nghiệm đối chứng để tách biệt hoàn toàn ảnh hưởng của rare-character oversampling và continued fine-tuning.
- Ngoài PP-OCRv6 Medium, đồ án chưa khảo sát sâu nhiều kiến trúc OCR hoặc Vision-Language Model khác.

Trong tương lai, hệ thống có thể được cải thiện bằng các chiến lược augmentation và sampling phù hợp hơn cho ký tự hiếm, xử lý dị thể chữ Hán có kiểm soát và khảo sát thêm các kiến trúc OCR hoặc Vision-Language Model hiện đại.